

Univerzitet u Beogradu

Matematički fakultet

Analiza ponašanja kupaca i performansi prodavaca u Olist platformi elektronske trgovine

Projekat iz predmeta Istraživanje podataka 2

Student	Jovana Brkljač
Broj indeksa	28/2022
Predmetni nastavnik	prof. dr Mirjana Maljković Ružičić
Predmet	Istraživanje podataka 2
Skup podataka	Olist Brazilian E-Commerce Public Dataset
Mesto i godina	Beograd, 2026.

Izveštaj je napisan na osnovu notebookova za razumevanje podataka, pripremu podataka, segmentaciju kupaca, segmentaciju prodavaca i klasifikaciju zadovoljstva kupaca.

Sažetak

Ovaj izveštaj prikazuje kompletan tok istraživanja nad javnim Olist skupom podataka, od početnog razumevanja relacionih tabela do formiranja analitičkih skupova i primene algoritama mašinskog učenja. Skup podataka nije unapred pripremljen za modelovanje: informacije o kupcima, porudžbinama, proizvodima, prodavcima, plaćanjima i recenzijama nalaze se u odvojenim tabelama, pa je centralni deo projekta bilo pravilno definisanje nivoa posmatranja i konstrukcija atributa.

U radu su realizovana tri zadatka. Prvi zadatak je segmentacija kupaca, gde se jedan red odnosi na jednog jedinstvenog kupca. Drugi zadatak je segmentacija prodavaca, gde se analiziraju poslovne, finansijske i logističke karakteristike prodavaca. Treći zadatak je klasifikacija zadovoljstva kupaca na nivou porudžbine, pri čemu je ciljna promenljiva izvedena iz ocene recenzije, a sama ocena uklonjena iz ulaznih atributa kako bi se izbeglo curenje informacija.

Za kupce su poređeni KMeans i BIRCH algoritmi. Iako BIRCH u pojedinim konfiguracijama ostvaruje višu silhouette vrednost, podela je često veoma neuravnotežena. Zato je kao finalno rešenje izabran KMeans sa četiri klastera, jer daje jasnije i korisnije segmente kupaca. Za prodavce su poređeni hijerarhijsko klasterovanje i Gaussian Mixture Model. Kao finalni model izabran je GMM sa tri komponente i dijagonalnom kovarijacionom matricom, jer ostvaruje dobar odnos između metrika i interpretabilnosti klastera.

U klasifikaciji zadovoljstva poređeni su Random Forest, XGBoost i XGBoost sa SMOTEENN balansiranjem. XGBoost ostvaruje najbolju ukupnu tačnost, ali zbog neuravnoteženosti klasa ne prepoznaje neutralne kupce. Model sa SMOTEENN balansiranjem ima nižu ukupnu tačnost, ali bolje tretira manjinske klase. Kroz sva tri zadatka pojavljuje se isti praktični zaključak: logistika, trajanje isporuke i kašnjenje imaju ključnu ulogu u korisničkom iskustvu i performansama prodavaca.

Struktura izveštaja

Poglavlje	Sadržaj
1	Uvod i ciljevi projekta
2	Razumevanje Olist skupa podataka
3	Priprema podataka i konstrukcija atributa
4	Standardizacija i smanjenje dimenzionalnosti
5	Segmentacija kupaca
6	Segmentacija prodavaca
7	Klasifikacija zadovoljstva kupaca
8	Diskusija rezultata i zaključak

I. Uvod


Elektronska trgovina generiše veliki broj podataka o kupcima, proizvodima, prodavcima, toku porudžbine, plaćanju, isporuci i zadovoljstvu korisnika. Takvi podaci su posebno vredni jer ne opisuju samo pojedinačne kupovine, već i celokupan odnos korisnika sa platformom. Pravilnom analizom moguće je prepoznati koji kupci imaju veću vrednost, koji prodavci nose najveći deo prihoda, koji faktori utiču na loše iskustvo i gde platforma može najefikasnije da interveniše.

U praksi, međutim, podaci retko dolaze u obliku jedne tabele spremne za primenu algoritama. Olist skup podataka ima relacionu strukturu: kupci, porudžbine, stavke porudžbine, plaćanja, recenzije, proizvodi i prodavci nalaze se u posebnim tabelama. Zbog toga prvi izazov nije izbor algoritma, već razumevanje strukture podataka i formiranje analitičkih tabela sa jasnim nivoom posmatranja.

U ovom projektu razlikuju se tri nivoa posmatranja. Kod segmentacije kupaca instanca je jedan stvarni kupac identifikovan preko `customer_unique_id`. Kod segmentacije prodavaca instanca je jedan prodavac. Kod klasifikacije zadovoljstva instanca je jedna porudžbina, jer je recenzija povezana sa konkretnim iskustvom kupovine. Ova razlika je metodološki važna: mešanje nivoa posmatranja može dovesti do pogrešnih zaključaka i modela koji izgledaju dobri metrički, ali nemaju jasno značenje.

Cilj rada nije bio samo da se primeni više algoritama, već da se izgradi kompletan tok istraživanja podataka. To uključuje razumevanje skupa, pripremu i agregaciju, obradu nedostajućih vrednosti, konstrukciju novih atributa, standardizaciju, smanjenje dimenzionalnosti, evaluaciju modela i tumačenje rezultata. Posebna pažnja posvećena je tome da se odluke ne donose mehanički na osnovu jedne metrike, već uzimajući u obzir interpretabilnost i poslovni smisao dobijenih rezultata.

Tok projekta i nivo posmatranja u svakom zadatku



Slika 1. Tok projekta od originalnih Olist tabela do tri zadatka modelovanja.

I.1. Ciljevi projekta

Prvi cilj je bio da se razume struktura podataka i razlika između identifikatora koji označavaju porudžbinu i identifikatora koji označavaju stvarnog kupca. Ova razlika je presudna za segmentaciju kupaca, jer bi korišćenje `customer_id` atributa vodilo ka grupisanju porudžbina, a ne kupaca.


Drugi cilj je bio formiranje master tabela koje su pogodne za primenu algoritama. U tom koraku uvedeni su atributi koji opisuju finansijsku vrednost, aktivnost, logistiku, zadovoljstvo i raznovrsnost proizvoda. Time su originalni relacioni podaci prevedeni u oblike koji nose informaciju relevantnu za konkretne zadatke.

Treći cilj bio je poređenje više algoritama za klasterovanje i klasifikaciju. Kod klasterovanja konačan izbor modela nije zasnovan samo na silhouette koeficijentu, već i na veličinama klastera i njihovoj interpretabilnosti. Kod klasifikacije, zbog neuravnoteženosti klasa, analizirane su različite metrike i ponašanje modela po klasama.

2. Razumevanje Olist skupa podataka

Olist Brazilian E-Commerce Public Dataset opisuje porudžbine realizovane na brazilskoj marketplace platformi. Skup sadrži podatke o kupcima, prodavcima, proizvodima, plaćanjima, recenzijama i vremenskom toku porudžbine. Zbog velikog broja tabela, prvi korak u analizi bio je identifikacija centralnih entiteta i njihovih veza.

Tabela orders predstavlja centralni entitet, jer svaka porudžbina povezuje kupca, stavke porudžbine, plaćanje i recenziju. Tabela order_items omogućava povezivanje porudžbine sa proizvodom i prodavcem, dok tabela reviews daje korisničku ocenu koja se kasnije koristi za formiranje ciljne promenljive u klasifikaciji zadovoljstva.



Slika 2. Pojednostavljena relacionala šema korišćena za pripremu podataka.

Tabela	Broj redova	Broj kolona	Uloga u analizi
customers	99 441	5	identifikacija kupaca i lokacija
orders	99 441	8	centralni entitet porudžbine
order_items	1 12 650	7	stavke porudžbine, proizvodi, prodavci i cene
payments	103 886	5	vrednost, tip i broj rata plaćanja
reviews	99 224	7	ocena i komentar kupca
products	32 951	9	kategorija i dimenzije proizvoda
sellers	3 095	4	prodavci i njihova lokacija
geolocation	1 000 163	5	geografske koordinate

Tabela 1. Veličina osnovnih tabela u Olist skupu podataka.


Tabela customers sadrži dva različita identifikatora: customer_id i customer_unique_id. Atribut customer_id se odnosi na konkretnu porudžbinu, dok customer_unique_id označava stvarnog korisnika. U podacima postoji 99 441 vrednost atributa customer_id i 96 096 jedinstvenih kupaca, što znači da deo kupaca ima više od jedne porudžbine. Zbog toga je za segmentaciju kupaca korišćen customer_unique_id.

Ova odluka je važna jer segmentacija treba da grupiše ponašanje kupaca kroz vreme, a ne samo pojedinačne kupovine. Kupac sa dve ili tri porudžbine može imati drugačiji profil od kupca sa jednom porudžbinom, pa bi analiza na nivou porudžbine izgubila deo informacije o lojalnosti i aktivnosti.

2.1. Kvalitet podataka i nedostajuće vrednosti

Analiza nedostajućih vrednosti pokazuje da najveći problem imaju tekstualne kolone recenzija. Kolona `review_comment_title` ima 88.34% nedostajućih vrednosti, a `review_comment_message` 58.70%. Ove kolone nisu korišćene u daljem modelovanju, pa njihov nedostatak ne ugrožava glavne zadatke projekta.

Sa druge strane, nedostajuće vrednosti u datumima isporuke imaju veći značaj, jer se iz tih kolona izvode trajanje isporuke i kašnjenje. Ako porudžbina nije isporučena ili datum nije zabeležen, ne sme se nekritički računati `delivery_days`. Zato je obrada vremenskih atributa urađena pažljivo, uz razlikovanje uspešno isporučenih i problematičnih porudžbina.




Slika 3. Najveći udeli nedostajućih vrednosti po kolonama.


2.2. Raspodela ocena, statusa i vremena

Raspodela ocena recenzije pokazuje da su kupci u većini slučajeva zadovoljni. Ocena 5 pojavljuje se 57 328 puta, a ocena 4 ukupno 19 142 puta. Klase niskog zadovoljstva su mnogo ređe, što unapred najavljuje problem neuravnoteženosti u klasifikaciji zadovoljstva.

Statusi porudžbina dodatno pokazuju da velika većina zapisa pripada uspešno realizovanim porudžbinama. Status delivered ima 96 478 porudžbina, dok su statusi shipped, canceled, unavailable i ostali znatno ređi. Upravo zbog toga atributi povezani sa isporukom imaju veliki značaj: većina kupaca je zadovoljna, a nezadovoljstvo se često javlja u slučajevima kada postoji kašnjenje ili problem sa tokom porudžbine.




Slika 4. Raspodela ocena recenzije.



Slika 5. Raspodela statusa porudžbina.

Vremenska serija broja porudžbina pokazuje rast platforme tokom posmatranog perioda, uz pad na samom kraju koji je posledica nepotpunog poslednjeg vremenskog intervala. Ova činjenica je važna kod tumačenja recency atributa, jer vreme poslednje kupovine zavisi od kraja posmatranog perioda u skupu podataka.




3. Priprema podataka i konstrukcija atributa

Priprema podataka predstavlja centralni deo projekta. Originalne tabele su pogodne za čuvanje podataka u sistemu elektronske trgovine, ali nisu pogodne za direktno modelovanje. Algoritmi klasterovanja i klasifikacije zahtevaju da svaka instanca bude opisana jednim redom, dok su informacije u Olist skupu raspoređene kroz više tabela i različite nivoe posmatranja.

Zbog toga je najpre formirana pomoćna tabela na nivou porudžbine. Ona povezuje informacije o kupcu, stavkama, proizvodima, prodavcima, plaćanjima, recenzijama i isporuci. Iz te tabele su zatim agregacijom izvedene `customer_master` i `seller_master` tabele, dok je `satisfaction_table` formirana za zadatak klasifikacije zadovoljstva.

Feature engineering: od relacionih tabela do analitičkih atributa



Slika 7. Konstrukcija atributa iz relacionih tabela.

Izvedena tabela	Broj redova	Broj kolona	Namena
customer_master	96 096	22	segmentacija kupaca pomoću KMeans i BIRCH algoritama
seller_master	3 095	17	segmentacija prodavaca pomoću hijerarhijskog klasterovanja i GMM modela
satisfaction_table	98 673	24	klasifikacija zadovoljstva kupaca pomoću Random Forest i XGBoost modela

Tabela 2. Master tabele formirane tokom pripreme podataka.

3.1. Atributi za kupce

Tabela `customer_master` formirana je agregacijom po `customer_unique_id`. Time svaki red predstavlja jednog stvarnog kupca, a ne jednu porudžbinu. Uvedeni su atributi koji opisuju aktivnost kupca, finansijsku vrednost, preferencije, iskustvo isporuke i zadovoljstvo.

Finansijski atributi kao što su `total_spent`, `total_items_value` i `avg_order_value` opisuju vrednost kupca za platformu. Atributi `order_count`, `unique_products`, `unique_categories` i `customer_lifetime_days` opisuju aktivnost i raznovrsnost kupovine. Atributi `avg_review_score`, `avg_delivery_days`, `avg_delay_days` i `delayed_order_rate` uvode dimenziju korisničkog iskustva, posebno u pogledu isporuke.

3.2. Atributi za prodavce

Tabela `seller_master` formirana je agregacijom po `seller_id`. Cilj je da svaki red opiše poslovni profil jednog prodavca. Uključeni su atributi obima prodaje, prihoda, broja kupaca, raznovrsnosti

proizvoda, prosečne ocene i logističkih performansi.

Kod prodavaca su pojedini atributi izrazito asimetrični. Većina prodavaca ima mali broj porudžbina i nizak prihod, dok mali broj prodavaca ostvaruje vrlo velike vrednosti. Zbog toga je nad nenegativnim numeričkim atributima sa desnom asimetrijom primenjena logIp transformacija. Ona smanjuje uticaj ekstremnih vrednosti, ali zadržava poredak prodavaca po posmatranom atributu.

3.3. Tabela za klasifikaciju zadovoljstva

Tabela `satisfaction_table` formirana je na nivou porudžbine, jer je ocena recenzije povezana sa konkretnim iskustvom kupovine. Ciljna promenljiva `satisfaction_class` izvedena je iz `review_score` atributa: klasa 0 označava nezadovoljne kupce, klasa 1 neutralne, a klasa 2 zadovoljne kupce.

Atribut `review_score` je nakon toga uklonjen iz ulaznih promenljivih. Ovo je neophodna odluka, jer bi korišćenje ocene iz koje je ciljna promenljiva direktno izvedena dovelo do curenja informacija. Model bi tada učio gotovo direktnu transformaciju cilja, pa bi rezultati bili nerealno dobri i metodološki pogrešni.

Kategorijski atributi transformisani su metodom One-Hot Encoding. Na taj način svaka kategorija postaje posebna binarna promenljiva, što omogućava primenu modela koji rade nad numeričkim ulazom. Numerički atributi su standardizovani, pri čemu se skaliranje u klasifikaciji fituje isključivo na trening skupu kako se informacija iz test skupa ne bi prenela u proces učenja.

3.4. Transformacije pre modelovanja

Standardizacija je primenjena zato što algoritmi zasnovani na rastojanjima mogu biti previše osetljivi na skalu atributa. Bez standardizacije, atributi sa velikim numeričkim opsegom, kao što je ukupna vrednost porudžbine, mogli bi dominirati nad atributima kao što su prosečna ocena ili stopa kašnjenja, iako su svi relevantni za segmentaciju.

Kod kupaca se nakon One-Hot Encoding-a dobija 125 atributa. Taj prostor je dovoljno visokodimenzionalan da oteža interpretaciju i rad pojedinih algoritama, pa je primenjena analiza glavnih komponenti. Kod prodavaca je PCA korišćen nakon log transformacije i standardizacije, a modeli i metrike računaju se u istom PCA prostoru. Interpretacija klastera se, međutim, radi nad originalnim atributima jer su oni poslovno razumljivi.

Uloga PCA u toku modelovanja



PCA ne bira originalne atribute, već formira nove linearne kombinacije (PC1, PC2, ...).

Slika 8. Uloga PCA u toku modelovanja.


4. Standardizacija i smanjenje dimenzionalnosti

PCA je korišćen kao metoda smanjenja dimenzionalnosti pre klasterovanja. Važno je naglasiti da PCA nije metoda selekcije atributa. Ona ne bira podskup originalnih kolona, već formira nove promenljive - glavne komponente - koje predstavljaju linearne kombinacije originalnih atributa. Zbog toga nije ispravno reći da je posle PCA 'ostalo 13 atributa'; ispravno je reći da je originalni prostor zamenjen sa 13 komponenti kod kupaca, odnosno 6 komponenti kod prodavaca.


Prag od 90% objašnjene varijanse predstavlja kompromis između očuvanja informacije i smanjenja složenosti. Niži prag bi više smanjio prostor, ali bi mogao ukloniti važne obrasce. Viši prag bi zadržao više informacija, ali bi smanjenje dimenzionalnosti bilo slabije. U ovom projektu 90% predstavlja razuman prag za klasterovanje, jer omogućava stabilnije modele uz očuvanje većeg dela varijanse.

4.1. PCA kod segmentacije kupaca

Kod kupaca je nakon pripreme dobijeno 125 atributa. Kumulativna objašnjena varijansa pokazuje da je za dostizanje praga od 90% potrebno 13 glavnih komponenti. To znači da je visokodimenzionalni prostor značajno sažet, ali bez gubitka većeg dela informacije koja opisuje razlike među kupcima.



Slika 9. Kumulativna objašnjena varijansa PCA komponenti za kupce.




Slika 10. Najuticajniji atributi u prvim PCA komponentama kupaca.

Prva glavna komponenta kod kupaca dominantno je povezana sa finansijskom vrednošću kupovine: ukupna potrošnja, vrednost kupljenih proizvoda i prosečna vrednost porudžbine imaju najveći doprinos. Druga komponenta opisuje aktivnost i širinu odnosa kupca sa platformom, jer najveći značaj imaju broj porudžbina, broj proizvoda, trajanje odnosa i broj kategorija. Treća komponenta je najviše vezana za isporuku i zadovoljstvo, pošto najveći doprinos imaju stopa kašnjenja, trajanje isporuke, prosečno kašnjenje i prosečna ocena.


Ova interpretacija je korisna jer pokazuje da PCA komponente nisu nasumične. One sažimaju logične grupe informacija: vrednost kupca, aktivnost kupca i kvalitet iskustva. Upravo zato se PCA prostor može koristiti za modelovanje, dok se poslovna interpretacija klastera i dalje oslanja na originalne attribute.

4.2. PCA kod segmentacije prodavaca

Kod prodavaca je polazni prostor manji nego kod kupaca, ali su razlike među instancama izraženije zbog nejednake raspodele prihoda i obima prodaje. Nakon standardizacije i PCA transformacije, za zadržavanje najmanje 90% varijanse potrebno je 6 komponenti. Time se zadržava najveći deo informacije, a istovremeno se smanjuje uticaj šuma i koreliranih atributa.




Slika 11. Kumulativna objašnjena varijansa PCA komponenti za prodavce.



Slika 12. Najuticajniji atributi u prvim PCA komponentama prodavaca.

Kod prodavaca prva komponenta najviše opisuje obim poslovanja: broj porudžbina, broj jedinstvenih kupaca, broj prodatih proizvoda, ukupna vrednost dostave i broj jedinstvenih proizvoda. Druga komponenta prvenstveno opisuje logističke performanse, jer uključuje prosečno trajanje isporuke, stopu kašnjenja i prosečno kašnjenje. Treća komponenta više je povezana sa finansijskim karakteristikama prodaje, naročito prosečnom cenom proizvoda i prosečnom vrednošću dostave.

Ovo je metodološki važno jer pokazuje da segmentacija prodavaca ne zavisi samo od prihoda. PCA izdvaja i logističku dimenziju, koja se kasnije pokazuje važnom u interpretaciji klastera i u klasifikaciji zadovoljstva kupaca.



Slika 13. Prikaz prodavaca u prostoru prve dve PCA komponente.

Raspodela prodavaca u prostoru prve dve PCA komponente pokazuje da se većina prodavaca nalazi u relativno kompaktnom delu prostora, dok se manji broj prodavaca udaljava od većine. To je očekivano za marketplace podatke, jer mali broj prodavaca ima znatno veći obim prodaje i prihoda.


Ovaj prikaz nije korišćen kao jedini osnov za izbor modela, ali je koristan za razumevanje strukture podataka. On potvrđuje da postoje postepene razlike među prodavcima, pa je opravdano porediti hijerarhijsko klasterovanje i GMM, a ne oslanjati se samo na jedan algoritam.

5. Segmentacija kupaca primenom algoritama klasterovanja

Cilj segmentacije kupaca je pronalaženje grupa korisnika koji imaju slične obrasce ponašanja. Pošto u ovom zadatku ne postoje unapred poznate oznake segmenata, kvalitet modela ne može se proceniti na isti način kao kod nadgledanog učenja. Zbog toga su korišćene interne metrike, raspodela veličina klastera i poslovna interpretacija profila klastera.

Za kupce su poređena dva algoritma: KMeans i BIRCH. KMeans je pogodan kada se očekuju relativno kompaktne grupe u numeričkom prostoru. BIRCH je zanimljiv jer je namenjen većim skupovima podataka i gradi hijerarhijsku strukturu podklastera. Pošto customer_master ima 96 096 kupaca, BIRCH je metodološki smislen kandidat za poređenje.

Evaluacija klasterovanja nije zasnovana samo na jednoj metrici



Model sa boljom metrikom nije izabran ako daje jedan dominantan ili neinterpretabilan klaster.

Slika 14. Okvir za izbor modela kod klasterovanja.

5.1. Evaluacija KMeans modela

Kod KMeans algoritma ispitane su vrednosti k od 2 do 8. Silhouette koeficijent meri koliko su instance bliske svom klasteru u odnosu na susedne klaster. Veća vrednost je bolja, ali metrika nije dovoljna sama po sebi. Rešenje može imati dobar silhouette rezultat ako izdvaja mali ekstremni klaster, dok većinu podataka ostavlja u jednom dominantnom segmentu.

U rezultatima se vidi da KMeans za $k=4$ ostvaruje silhouette 0.2226, dok $k=6$ ostvaruje vrlo sličnu vrednost 0.2228. Međutim, kod $k=6$ najmanji klaster obuhvata samo 0.70% kupaca, što otežava stabilnu interpretaciju. Zbog toga je $k=4$ izabrano kao finalno KMeans rešenje: metrika je dobra, a najmanji klaster i dalje prelazi prag od 2.5% kupaca.


k	Silhouette	Najveći klaster (%)	Najmanji klaster (%)	Komentar
2	0.1993	57.84	42.16	pregruba podela
3	0.2040	55.60	2.60	prihvatljivo, ali manje detaljno
4	0.2226	51.76	2.59	izabrano rešenje
5	0.1683	42.53	2.57	lošija metrika
6	0.2228	46.91	0.70	premali klaster
7	0.1825	35.63	0.70	premali klaster
8	0.1678	32.28	0.70	premali klaster

Tabela 3. Rezultati KMeans algoritma za različite vrednosti

5.2. Zašto BIRCH nije izabran

BIRCH za $k=2$ ostvaruje silhouette vrednost 0.5108, što je znatno više od KMeans rezultata. Međutim, raspodela klastera pokazuje da jedan klaster sadrži 96.90% kupaca. Takvo rešenje je metrički privlačno, ali nije korisno za segmentaciju kupaca, jer većinu korisnika svrstava u jedan dominantan segment.


Sličan problem se javlja i kod BIRCH rešenja sa više klastera. Kod $k=4$ silhouette je 0.2689, ali najveći klaster i dalje obuhvata 81.80% kupaca. To znači da BIRCH pre svega izdvaja manje grupe odstupajućih kupaca, dok ne daje dovoljno bogatu segmentaciju većinskog dela korisničke baze.



Slika 15. Silhouette vrednosti za KMeans i BIRCH na skupu kupaca.

Model	Konfiguracija	Silhouette	Raspodela klastera	Zaključak
KMeans	$k=4$	0.2226	51.76%, 2.59%, 39.21%, 6.44%	finalni model za kupce
BIRCH	$k=4$	0.2689	81.80%, 3.10%, 8.68%, 6.42%	viša metrika, ali dominantan klaster
BIRCH	$k=2$	0.5108	96.90%, 3.10%	slabo informativno za segmentaciju

Tabela 4. Poređenje interpretabilnosti KMeans i BIRCH rešenja.




Slika 16. Poređenje metrika i raspodele klastera kod kupaca.

5.3. Profilisanje finalnih klastera kupaca

Profilisanje klastera urađeno je nad originalnim atributima, a ne nad PCA komponentama. To je važno jer PCA prostor služi za stabilnije modelovanje, dok originalni atributi omogućavaju poslovnu interpretaciju. Klaster se može razumeti tek kada se opiše kroz potrošnju, broj porudžbina, ocenu, vreme isporuke i kašnjenje.



Slika 17. Veličine finalnih KMeans klastera kupaca.



Slika 18. Standardizovani profil finalnih klastera kupaca.

Klaster 0 obuhvata najveći broj kupaca. Karakterišu ga niža ukupna potrošnja i manja prosečna vrednost porudžbine, ali dobre ocene i uglavnom negativno prosečno kašnjenje, što znači da porudžbine najčešće stižu pre procenjenog roka. Ovaj segment predstavlja široku bazu standardnih kupaca koji kupuju povremeno i nemaju izraženo loše iskustvo.


Klaster 1 je najmanji, ali poslovno najvredniji. Ima veći broj porudžbina, najveću ukupnu potrošnju i veći broj jedinstvenih proizvoda. Iako je mali po broju instanci, ovaj segment je važan jer pokazuje aktivnije kupce koji platformi donose veći prihod. Kod ovakvih kupaca smisleni su programi lojalnosti, personalizovane preporuke i posebna pažnja ka zadržavanju.

Klaster 2 obuhvata kupce sa većom prosečnom vrednošću porudžbine, ali bez izrazito velikog broja kupovina. To su kupci koji ne kupuju često, ali njihove pojedinačne kupovine imaju veću vrednost. Za ovaj segment relevantne su preporuke skupljih ili komplementarnih proizvoda.

Klaster 3 je posebno važan sa aspekta korisničkog iskustva. Ima najnižu prosečnu ocenu i pozitivno prosečno kašnjenje. To ukazuje na kupce kod kojih postoji veći rizik nezadovoljstva. Iako ovaj klaster nije najveći, njegov značaj je visok jer može pomoći platformi da prepozna problematične obrasce isporuke i pravovremeno reaguje.

Klaster	Dominantne osobine	Moguće tumačenje
0	niža potrošnja, dobre ocene, manja kašnjenja	standardni povremeni kupci
1	najveća ukupna potrošnja, više porudžbina i proizvoda	aktivni i vredni kupci
2	veća prosečna vrednost porudžbine	kupci sa skupljim pojedinačnim kupovinama
3	niže ocene i pozitivno kašnjenje	kupci sa slabijim iskustvom isporuke

Tabela 5. Sažeta interpretacija finalnih klastera kupaca.



Slika 19. Vizuelizacija KMeans klastera kupaca u prostoru prve dve PCA komponente.

6. Segmentacija prodavaca


Segmentacija prodavaca razlikuje se od segmentacije kupaca po broju instanci i raspodeli atributa. U seller_master tabeli postoji 3 095 prodavaca, ali su razlike u obimu poslovanja veoma izražene. Mali broj prodavaca generiše veliki deo prometa, dok većina prodavaca ima mali broj porudžbina i nizak prihod. Zbog toga su log transformacija, standardizacija i PCA posebno važni u ovom delu projekta.

Za prodavce su poređena dva pristupa: Agglomerative Clustering i Gaussian Mixture Model. Hijerarhijsko klasterovanje omogućava ispitivanje različitih načina povezivanja instanci, dok GMM modelira podatke kao kombinaciju verovatnosnih komponenti i može bolje opisati klasterne koji nemaju strogo sferičan oblik.

6.1. Hijerarhijsko klasterovanje

Kod hijerarhijskog klasterovanja analizirane su Ward, Complete i Average strategije povezivanja za različiti broj klastera. Prilikom izbora modela nisu posmatrane samo vrednosti evaluacionih metrika, već i raspodela prodavaca po klasterima, kako bi segmentacija bila korisna za dalju interpretaciju. Rezultati pokazuju da Complete i Average povezivanje za mali broj klastera ostvaruju visoke silhouette vrednosti, ali pri tome više od 98% prodavaca završava u jednom klasteru, dok preostali klasteri sadrže veoma mali broj instanci. Takva segmentacija nije pogodna za analizu poslovnih karakteristika prodavaca.

Najbolje rešenje u okviru hijerarhijskog klasterovanja ostvaruje Ward povezivanje sa četiri klastera. Iako silhouette vrednost iznosi 0.2183, klasteri su znatno uravnoteženiji i bolje odražavaju razlike između prodavaca. Ipak, najmanji klaster obuhvata svega 2.78% instanci, zbog čega je bilo potrebno razmotriti i fleksibilniji model za konačnu segmentaciju.




Slika 20. Silhouette vrednosti za hijerarhijsko klasterovanje prodavaca.

6.2. Gaussian Mixture Model i poređenje modela

Gaussian Mixture Model predstavlja probabilistički pristup klasterovanju koji pretpostavlja da podaci nastaju kao mešavina više Gausovih raspodela. Za razliku od hijerarhijskog klasterovanja, GMM ne dodeljuje instancu isključivo jednom klasteru, već procenjuje verovatnoću pripadnosti svakoj komponenti. Zbog toga može uspešnije opisati podatke kod kojih granice između klastera nisu potpuno jasno definisane.

Tokom eksperimenta ispitane su pune (full) i dijagonalne (diag) kovarijacione matrice za različit broj komponenti. Full kovarijaciona matrica omogućava modelovanje korelacije između svih atributa i formiranje klastera proizvoljnog oblika, ali zahteva procenu većeg broja parametara. Sa druge strane, diag matrica zanemaruje međusobnu korelaciju atributa, što rezultuje jednostavnijim i stabilnijim modelom. Kao najbolje rešenje izdvojio se GMM sa tri komponente i dijagonalnom kovarijacionom matricom, koji ostvaruje silhouette vrednost od 0.2542, pri čemu najmanji klaster obuhvata 14.09%, a najveći 52.89% prodavaca. Iako ne postiže najbolju Davies–Bouldin vrednost, ovakav model daje znatno uravnoteženiju raspodelu klastera i jednostavniju poslovnu interpretaciju, zbog čega je izabran kao finalni model.



Slika 21. Poređenje finalnih kandidata za segmentaciju prodavaca.

Grafikon jasno pokazuje kompromis između metrika i stabilnosti klastera. GMM ima nešto viši silhouette i znatno veći najmanji klaster, što znači da ne formira ekstremno malu grupu prodavaca. Agglomerative rešenje sa Ward povezivanjem ima niži Davies-Bouldin, ali minimalni klaster od 2.78% otežava tumačenje i upotrebu segmenta.

Zbog toga je GMM izabran kao finalni model, ne zato što je apsolutno najbolji po svakoj metrici, već zato što daje najkorisniji odnos između evaluacionih vrednosti, raspodele klastera i poslovne interpretacije.

Model	Konfiguracija	Silhouette	Davies-Bouldin	Min klaster (%)	Max klaster (%)
Agglomerative	ward, k=4	0.2183	1.2599	2.7787	41.6478
GMM	diag, k=3	0.2542	1.6190	14.0872	52.8918

Tabela 6. Poređenje finalnih konfiguracija za klasterovanje prodavaca.


6.3. Interpretacija finalnih klastera prodavaca

Kao finalni model izabran je GMM sa tri klastera. Prednost ovog rešenja je u tome što klasteri imaju jasno poslovno značenje: prodavci sa slabijim logističkim performansama, vodeći prodavci i mali prodavci sa niskim obimom poslovanja.


Klaster 0 obuhvata 14.09% prodavaca. Ovi prodavci imaju prosečno 5.85 porudžbina i 6.66 prodatih proizvoda, ali se izdvajaju po visokoj prosečnoj vrednosti dostave, najnižoj prosečnoj oceni od 3.48, najdužem prosečnom vremenu isporuke od 19.05 dana i najvećoj stopi kašnjenja od 0.24. Ovaj segment ukazuje na prodavce kod kojih logistika i korisničko iskustvo zahtevaju unapređenje.

Klaster 1 je najvažniji za platformu. Čini 52.89% prodavaca, ali generiše 88.47% ukupnog prihoda. Prodavci u ovom segmentu imaju prosečno 58.19 porudžbina, 65.46 prodatih proizvoda i najveći prosečan prihod. Ovaj klaster predstavlja vodeće prodavce i nosioce prodaje.

Klaster 2 čini 33.02% prodavaca, ali generiše samo 1.79% prihoda. To su mali ili povremeno aktivni prodavci, sa prosečno 2.15 porudžbina i 2.53 prodata proizvoda. Njihove logističke performanse nisu najlošije, ali zbog niskog obima prodaje imaju mali uticaj na ukupan prihod platforme



Slika 22. Standardizovani profil finalnih GMM klastera prodavaca.




Slika 23. Udeo prodavaca i prihoda po finalnim GMM klasterima.

Klaster	Udeo prodavaca	Udeo prihoda	Tumačenje
0	14.09%	9.74%	prodavci sa slabijim logističkim performansama
1	52.89%	88.47%	vodeći prodavci i nosioci prihoda
2	33.02%	1.79%	mali ili povremeno aktivni prodavci

Tabela 7. Sažeta interpretacija finalnih klastera prodavaca.

Analiza kategorija proizvoda i geografske raspodele pokazuje da se finalni klasteri ne razlikuju prvenstveno po lokaciji ili tipu proizvoda. Svi klasteri su dominantno zastupljeni u državi Sao Paulo, a iza nje se izdvajaju Parana, Minas Gerais i Santa Catarina. To ukazuje da je model pre svega uhvatio poslovne performanse, prihod, ocene i logistiku, dok lokacija i kategorija imaju sekundarnu ulogu.

Ovakav rezultat je praktično koristan. Platforma može posebno pratiti klaster 0, jer on ukazuje na prodavce kod kojih je korisničko iskustvo slabije. Sa druge strane, klaster 1 predstavlja prodavce koje je važno zadržati i podržati, jer nose najveći deo prihoda. Klaster 2 može biti cilj programa aktivacije malih prodavaca.




Slika 24. Vizuelizacija GMM klastera prodavaca u prostoru prve dve PCA komponente.

7. Klasifikacija zadovoljstva kupaca


Treći zadatak je predikcija zadovoljstva kupaca na osnovu karakteristika porudžbine. Tabela `satisfaction_table` ima 98 673 reda i 24 kolone. Nakon uklanjanja identifikatora i atributa `review_score`, kao i nakon One-Hot Encoding transformacije, dobijen je skup sa 127 ulaznih atributa. Skup je podeljen na trening deo od 78 938 instanci i test deo od 19 735 instanci.

Ciljna promenljiva ima tri klase: klasa 0 označava nezadovoljne kupce, klasa 1 neutralne, a klasa 2 zadovoljne kupce. Raspodela je izrazito neuravnotežena: 77.11% instanci pripada klasi zadovoljnih kupaca, 14.64% klasi nezadovoljnih, a samo 8.25% neutralnim kupcima. Zbog toga ukupna tačnost nije dovoljna za procenu modela.

Tok klasifikacije zadovoljstva kupaca



Slika 25. Tok klasifikacije zadovoljstva kupaca.



Slika 26. Raspodela klasa zadovoljstva kupaca.

Skup	Broj instanci	Broj atributa	Klasa 0	Klasa 1	Klasa 2
Trening	78 938	127	14.64%	8.25%	77.11%
Test	19 735	127	14.64%	8.24%	77.11%

Tabela 8. Podela na trening i test skup uz očuvanu raspodelu klasa.

7.1. Evaluacione metrike

Accuracy meri udeo tačno klasifikovanih instanci. Kod neuravnoteženih podataka ova metrika može biti varljiva, jer model može ostvariti visoku tačnost favorizovanjem dominantne klase. U ovom slučaju model koji često predviđa klasu 2 može imati solidnu tačnost, a da pritom gotovo uopšte ne prepoznaje neutralne kupce.

Precision pokazuje koliko su predikcije određene klase pouzdane, dok recall pokazuje koliki deo stvarnih instanci te klase model uspeva da pronađe. F1-score predstavlja harmonijsku sredinu precision i recall vrednosti. Kod ovog zadatka posebno je važno posmatrati rezultate po klasama, jer ukupni F1-score može prikriti loše ponašanje nad manjinskom klasom 1.


Zbog toga su pored ukupnih metrika analizirane i matrice konfuzije. One pokazuju kako se stvarne klase raspoređuju po predikcijama modela i direktno otkrivaju da li model ignoriše neku klasu. Ovaj uvid je ključan za tumačenje rezultata XGBoost modela.

7.2. Modeli

Random Forest je korišćen kao stabilan ansambl model zasnovan na većem broju stabala odlučivanja. Prednost ovog modela je robusnost i mogućnost računanja značaja atributa. U projektu je treniran uz `class_weight='balanced'`, kako bi se delimično kompenzovala neuravnoteženost klasa.

XGBoost je korišćen kao snažan ansambl sekvencijalno građenih stabala. On često daje najbolje rezultate na tabelarnim podacima jer svako sledeće stablo uči na greškama prethodnih. U ovom projektu XGBoost ostvaruje najbolju ukupnu tačnost, ali detaljna analiza pokazuje da ne prepoznaje neutralne kupce.

Treći pristup koristi XGBoost nakon SMOTEENN balansiranja. SMOTEENN kombinuje generisanje sintetičkih primera manjinskih klasa i uklanjanje nejasnih ili problematičnih instanci. Time se trening skup menja tako da model dobija više informacija o manjinskim klasama, ali se istovremeno povećava rizik smanjenja ukupne tačnosti na originalnom test skupu.



Slika 27. Poređenje klasifikacionih modela.

Algoritam	Accuracy	Precision	Recall	F1-score	Tumačenje
Random Forest	0.7142	0.7467	0.7142	0.7289	stabilniji na manjinskim klasama od osnovnog XGBoost-a
XGBoost	0.8172	0.7422	0.8172	0.7699	najbolja ukupna tačnost, ali ne prepoznaje klasu 1
XGBoost + SMOTEENN	0.6977	0.7439	0.6977	0.7175	niža ukupna tačnost, ali bolji tretman manjinskih klasa

Tabela 9. Rezultati klasifikacionih modela.


7.3. Tumačenje rezultata po modelima

Random Forest ostvaruje tačnost 71.42%. Iako nije najbolji po ukupnoj metrici, ponaša se ravnomernije nad klasama. Za klasu 0 postiže precision 0.50 i recall 0.57, a za klasu 1 ima slabe, ali nenulte rezultate. To znači da model ima određenu sposobnost prepoznavanja nezadovoljnih i neutralnih kupaca.

XGBoost ostvaruje najbolju ukupnu tačnost od 81.72% i najveći F1-score od 0.7699. Međutim, za klasu 1 ima precision 0.00, recall 0.00 i F1-score 0.00. Model je veoma uspešan u prepoznavanju dominantne klase 2, ali praktično ignoriše neutralne kupce. Zbog toga je XGBoost dobar ako je cilj opšta tačnost, ali nije dovoljan ako je cilj prepoznavanje svih tipova korisničkog iskustva.

XGBoost + SMOTEENN smanjuje ukupnu tačnost na 69.77%, ali poboljšava tretman manjinskih klasa. Za klasu 1 postiže recall 0.19, dok osnovni XGBoost za tu klasu nema uspešnih predikcija. To pokazuje klasičnu razmenu između ukupne tačnosti i osetljivosti na retke klase. U poslovnom kontekstu, model sa balansiranjem može biti korisniji ako platforma želi rano upozorenje na potencijalno problematične porudžbine.

Matrice konfuzije za klasifikacione modele



Slika 28. Matrice konfuzije za sva tri klasifikaciona modela.


Matrice konfuzije potvrđuju zaključak iz numeričkih metrika. Osnovni XGBoost gotovo sve neutralne kupce svrstava u klasu zadovoljnih, pa zbog toga za klasu 1 ima nulte vrednosti precision, recall i F1. Random Forest pravi više grešaka nad dominantnom klasom, ali ipak prepoznaje deo neutralnih i nezadovoljnih kupaca.

SMOTEENN balansiranje menja ponašanje XGBoost modela: ukupna tačnost opada, ali se povećava broj prepoznatih neutralnih kupaca. Zato se izbor između osnovnog XGBoost-a i balansirane varijante mora donositi prema poslovnom cilju, a ne samo prema ukupnoj tačnosti.

7.4. Najvažniji atributi

Analiza značaja atributa u Random Forest modelu pokazuje da su najvažniji faktori povezani sa isporukom. Najveći značaj imaju `delay_days`, `order_status_delivered`, `is_delayed` i `delivery_days`. Finansijski atributi, kao što su ukupna vrednost dostave, prosečna cena proizvoda i ukupna vrednost plaćanja, imaju manji, ali vidljiv uticaj.

Ovaj rezultat je važan zato što se poklapa sa zaključcima iz klasterovanja. Kod kupaca se izdvaja segment sa lošijim iskustvom isporuke, kod prodavaca postoji klaster sa slabijim logističkim performansama, a kod klasifikacije zadovoljstva upravo atributi isporuke dominiraju u značaju. To pokazuje da tri zadatka nisu izolovana, već se međusobno potvrđuju.



Slika 29. Najvažniji atributi prema Random Forest modelu.

8. Diskusija rezultata i zaključak

Rezultati sva tri zadatka vode ka istom opštem zaključku: logistika ima veliki uticaj na korisničko iskustvo u Olist sistemu. Kod kupaca se izdvaja klaster sa nižim ocenama i pozitivnim prosečnim kašnjenjem. Kod prodavaca postoji segment sa najdužim prosečnim vremenom isporuke, najnižim ocenama i najvećom stopom kašnjenja. Kod klasifikacije zadovoljstva najvažniji atributi su upravo kašnjenje, status isporuke i trajanje isporuke.

Drugi važan zaključak je da izbor modela ne sme biti mehanički. BIRCH kod kupaca ostvaruje visoku silhouette vrednost za $k=2$, ali jedan klaster sadrži 96.90% kupaca. Slično tome, pojedine konfiguracije hijerarhijskog klasterovanja prodavaca imaju visoke metričke rezultate jer izdvajaju mali ekstremni klaster. Takva rešenja mogu biti matematički uredna, ali nisu nužno korisna za interpretaciju.

Zadatak	Glavni rezultat	Zajednički zaključak
Segmentacija kupaca	klaster sa lošijim iskustvom isporuke	kašnjenje utiče na zadovoljstvo
Segmentacija prodavaca	klaster sa slabijim logističkim performansama	prodavci utiču na kvalitet iskustva
Klasifikacija zadovoljstva	najvažniji atributi su delay_days, is_delayed i delivery_days	logistika je ključni signal zadovoljstva

Tabela 10. Povezivanje zaključaka iz sva tri zadatka.

8.1. Ograničenja

Kod klasterovanja ne postoje stvarne oznake segmenata, pa se kvalitet procenjuje internim metrikama i interpretacijom profila. To znači da finalni klasteri nisu jedino moguće rešenje, već interpretabilna segmentacija zasnovana na izabranim atributima i metrikama.

PCA smanjuje dimenzionalnost i stabilizuje rad algoritama, ali njegove komponente nisu direktno poslovno interpretabilne. Zbog toga se interpretacija klastera mora raditi nad originalnim atributima, a ne nad vrednostima PC1, PC2 i drugih komponenti.

Kod klasifikacije je najveće ograničenje neuravnoteženost klasa, naročito mali broj neutralnih kupaca. Zbog toga model koji ima dobru ukupnu tačnost može imati loš rezultat nad klasom 1. Uključivanje teksta komentara recenzija, dodatno podešavanje pragova ili drugačije definisanje ciljne promenljive mogli bi poboljšati rezultate.

8.2. Praktične implikacije

Sa praktične strane, platforma bi najviše koristi imala od praćenja rizičnih porudžbina i prodavaca sa slabijim logističkim pokazateljima. Ako se rano identifikuju porudžbine sa visokim rizikom kašnjenja, moguće je obavestiti kupca, ponuditi podršku ili prioritarno pratiti isporuku.

Segmentacija kupaca može se koristiti za različite strategije komunikacije. Vredni aktivni kupci mogu biti cilj programa lojalnosti, kupci sa većom prosečnom vrednošću porudžbine mogu dobiti personalizovane preporuke, dok kupci sa lošijim iskustvom isporuke zahtevaju poseban tretman kako bi se smanjio rizik odlaska sa platforme.

Segmentacija prodavaca može pomoći platformi da razlikuje vodeće prodavce od malih ili logistički problematičnih prodavaca. Vodećim prodavcima treba obezbediti podršku i zadržavanje, dok prodavcima sa slabijim logističkim performansama treba ponuditi operativnu podršku ili strože praćenje kvaliteta usluge.

Zaključak

U projektu je iz Olist relacionog skupa podataka izgrađen kompletan tok istraživanja podataka. Najpre je analizirana struktura tabela i kvalitet podataka, zatim su formirane tri master tabele, a potom su primenjeni algoritmi klasterovanja i klasifikacije. Najvažniji deo projekta nije bila sama primena algoritama, već pravilno definisanje nivoa posmatranja i tumačenje rezultata u kontekstu problema.

Za kupce je kao finalni model izabran KMeans sa četiri klastera. Dobijeni segmenti razlikuju se po vrednosti kupovine, aktivnosti, prosečnoj oceni i kvalitetu isporuke. BIRCH je ostvarivao više silhouette vrednosti u pojedinim konfiguracijama, ali su dobijeni klasteri bili previše neuravnoteženi za korisnu interpretaciju.

Za prodavce je kao finalni model izabran GMM sa tri klastera i dijagonalnom kovarijacionom matricom. Najveći klaster prodavaca generiše najveći deo prihoda platforme, dok drugi segmenti ukazuju na prodavce sa slabijim logističkim performansama ili niskim obimom poslovanja.

Kod klasifikacije zadovoljstva XGBoost ostvaruje najbolju ukupnu tačnost, ali zbog neuravnoteženosti klasa ne prepoznaje neutralne kupce. Random Forest i XGBoost sa SMOTEENN balansiranjem pokazuju da se manjinske klase mogu tretirati ravnomernije, ali uz pad ukupne tačnosti. Zato se konačan izbor modela mora prilagoditi poslovnom cilju, a ne zasnivati samo na jednoj metrici.

Najvažniji zaključak rada jeste da zadovoljstvo kupaca i performanse prodavaca u velikoj meri zavise od logistike. Kašnjenje, trajanje isporuke i status porudžbine pojavljuju se kao ključni faktori u više nezavisnih delova analize. Zbog toga bi platforma najviše koristi imala od praćenja rizičnih porudžbina, podrške prodavcima sa slabijim logističkim pokazateljima i posebnog tretmana kupaca koji su imali loše iskustvo isporuke.